Relatório de Prestação de Serviços

Contrato nº 2514753 - Empresa Municipal de Informática SA - IplanRio - CVL PRO-2025/01822

- **Período de faturamento:** 1º de Março de 2026 a 31 de Março de 2026
- **Valor total do contrato:** R$ 130.168.560,00 (cento e trinta milhões, cento e sessenta e oito mil e quinhentos e sessenta reais)

Cliente: Secretaria Municipal da Casa Civil

1. Resumo Faturamento

Linha de custo	Preço total
Horas de desenvolvimento	R$ 65.135,00
Licenciamento da plataforma	R$ 11.250,00
Atendimento ativo (utilidade)	R$ 7.572,50
Atendimento receptivo (sessões dentro de 24h)	R$ 3.481,66
Total	**R$ 87.439,16**

2. Desenvolvimento

Item	Serviço	Horas desenvolvimento	Valor da hora	Preço total
1	Lançamento do fluxo de incidentes hídricos	100	R$ 186,10	R$ 18.610,00
2	Correções de erros e melhorias gerais	150	R$ 186,10	R$ 27.915,00
3	Refatoração do System Prompt	100	R$ 186,10	R$ 18.610,00
Total		**350**	**-**	**R$ 65.135,00**

3. Atendimento

3.1. Atendimento Ativo

Categoria HSM	Mensagens entregues	Custo unitário	Preço total
Atendimento ativo (Utilidade)	58.250	R$ 0,13	R$ 7.572,50
Total geral	**58.250**	-	R$ 7.572,50

Campanha	Tentativas Disparo	Mensagens entregues	Taxa de entrega
Agendamento Cadúnico	43.968	41.660	94,75%
Cartão Pequenos Cariocas	9.477	8.794	92,79%
Pesquisa 1746	4.203	4.004	95,27%
Autenticação Pref.Rio	3.103	2.994	96,49%
Cobrança Dívida Ativa	485	454	93,61%
Teste interno - Incidentes hídricos	194	194	100,00%
Teste interno - Puérperas	168	150	89,29%
Total geral	**61.598**	**58.250**	**94,56%**

3.2. Atendimento Receptivo

Item	Volume Sessões	Custo unitário	Preço total
Atendimento receptivo (sessões de 24 horas fixas)	49.738	R$ 0,07	**R$ 3.481,66**

4. Licenciamento

Item	Sessões Receptivas (24h)	Faixa apurada	Preço total
Licenciamento da plataforma	49.738	Até 50.000	**R$ 11.250,00**

5. Detalhamento entregas

5.1. Fluxo de incidentes hídricos (Columbia)

Foi implementado e disponibilizado o fluxo de atendimento para incidentes hídricos, permitindo que o agente de IA oriente cidadãos em situações de risco relacionadas a chuvas, alagamentos e enchentes.

O fluxo contempla orientações preventivas, suporte em situações emergenciais e direcionamento para pontos de apoio e canais oficiais, com base em protocolos estruturados e atualizados. A solução também permite atuação contextualizada conforme o nível de risco informado pelo usuário, priorizando segurança e clareza nas instruções.

Essa entrega amplia a capacidade do agente em cenários críticos, oferecendo suporte ágil e confiável à população em situações de emergência.

5.2. Correções de erros e melhorias gerais

Foram realizadas diversas correções e melhorias técnicas em diferentes componentes da plataforma, com foco em aumentar a confiabilidade, a qualidade do código e a robustez dos processos de deploy e operação.

Destacam-se a automação de deploys e testes, correções em processamento de filas e envio de alertas, além de uma revisão funcional completa da aplicação, garantindo estabilidade dos fluxos e ausência de falhas visíveis ao usuário.

Também foram realizadas ações de limpeza técnica e organização do código, contribuindo para maior manutenção.

Adicionalmente, foi corrigido um problema no pipeline de dados que interrompia a atualização do histórico de conversas no BigQuery. A solução envolveu ajustes no mecanismo de processamento e recuperação dos dados, restabelecendo a integridade das informações analíticas.

Essas melhorias reforçam a estabilidade do sistema, a confiabilidade dos dados e a maturidade operacional da solução.

5.3. Refatoração do system prompt

Foi realizada a refatoração do system prompt do agente, resultando em redução significativa de seu tamanho, com manutenção ou melhoria do desempenho na maioria das métricas avaliadas.

A nova versão apresentou melhor relação entre custo e performance, além de incluir mecanismos para acompanhamento de tokens e facilitar o versionamento e a gestão do prompt. Essa evolução contribui para maior eficiência operacional e governança sobre o comportamento do agente.

6. Indicadores e níveis de serviço

Os serviços deverão atender, de forma contínua e ininterrupta, aos indicadores e metas de desempenho definidos no Termo de Referência e Edital.

6.1. Sessões receptivas

- Os dados de origem utilizados para o cálculo foram obtidos a partir de uma extração direta ao banco de dados de produção do fornecedor do *broker* (Wetalkie) e estão disponíveis no anexo II deste relatório e suas respectivas visualizações resumidas disponibilizadas no anexo III através de importação da base de origem em formato de tabela no datalake municipal.
- Para agrupamento das sessões receptivas, conforme consta em contrato, utilizamos a seguinte metodologia:
    - A partir da primeira mensagem enviada pelo cidadão (separação por números de telefone distintos), abre-se uma janela de 24 horas corridas. A partir daí todas as mensagens dentro desse intervalo são contabilizadas como parte da mesma sessão aberta. Uma nova mensagem do cidadão enviada após a janela de 24 horas corridas configura a abertura de uma nova sessão.
- Volume aferido: 49.738 sessões.

6.2. Implementação

- Nível de serviço alvo: Cumprimento de 100% dos prazos acordados para cada serviço implantado solicitado pela contratante.
- Resultado aferido: 100%.

Implementações - Mar/2026	Formato	Data acordada	Data Entrega	Status Prazo
Disparos ativos - Lembrete agendamento CadÚnico	Pipeline disparo	01/03/2026	01/03/2026	✅
Disparos ativos - Pesquisa 1746	Pipeline disparo	01/03/2026	01/03/2026	✅
Disparos ativos - Dívida Ativa (Lembrete pagamento)	Pipeline disparo	20/03/2026	20/03/2026	✅
Disparos ativos - Cartão Pequenos Cariocas	Pipeline disparo	20/03/2026	20/03/2026	✅
Disparos ativos - Dívida Ativa (Confirmação pagamento)	Pipeline disparo	23/03/2026	23/03/2026	✅
Disparos ativos - Dívida Ativa (Aviso)	Pipeline disparo	31/03/2026	31/03/2026	✅
Disparos ativos - Projeto Columbia	Pipeline disparo	31/03/2026	31/03/2026	✅
Lançamento do fluxo de incidentes hídricos (Columbia)	Nova implementação	30/03/2026	30/03/2026	✅
Refatoração do System Prompt	Nova implementação	18/03/2026	18/03/2026	✅

6.3. Latência

- Nível de serviço alvo: Latência de entrega de mensagens em até 01 (um) minuto em 98% dos casos.
- Resultado aferido: 98% das mensagens entregues em até 34.12 segundos.

A latência (ou tempo total de processamento ou E2E) é calculada usando os *traces* gerados em cada etapa do fluxo. Cada etapa produz um *span* com horários de início e fim; assim, o E2E é obtido pela diferença entre o *startTime* do primeiro *span* e o *endTime* do último *span*, representando o tempo completo de processamento da requisição no sistema distribuído.
Para verificar o resultado apresentado, disponibilizamos um script de validação no Anexo V deste relatório. O procedimento para utilização é o seguinte:

1) Obtenção dos dados: Acesse o Anexo III e realize o download da aba "Base bruta - Timestamp - Requests" em formato CSV.
2) Execução do script: Execute o comando abaixo no terminal, substituindo o caminho pelo local onde o arquivo foi salvo:
```
python e2e_p98.py caminho/para/seus/dados/brutos.csv
```
3) Processamento realizado pelo script:
   - Limpeza do arquivo CSV (remoção de cabeçalhos e linhas extras)
   - Leitura e parsing dos timestamps de início e fim
   - Cálculo da diferença temporal em segundos para cada registro
   - Cálculo do percentil 98 (P98) utilizando ordenação e interpolação linear
   - Exibição do resultado no console

O método de cálculo do P98 está documentado em detalhes através de comentários inline no código-fonte do script (Anexo V), permitindo a compreensão completa da metodologia aplicada.

6.4. Disponibilidade

- Nível de serviço alvo: Disponibilidade da plataforma: 99,9% por mês.
- Resultado aferido: 99,989%

A disponibilidade é medida fazendo requisições ao *endpoint* de *readiness* a cada 5 minutos. Esse *endpoint* verifica se todos os componentes críticos do sistema estão saudáveis. Quando a checagem retorna OK, o sistema é considerado disponível naquele intervalo; quando falha, é marcado como indisponível. A partir dessas verificações periódicas, calcula-se o percentual de tempo em que o sistema permaneceu operacional.
A partir do acesso ao dashboard de monitoramento da disponibilidade, é possível aferir o indicador de disponibilidade do chatbot durante o mês de Fevereiro. Para fins de auditoria do dashboard, deve-se verificar a query disponibilizada no Anexo III, intitulada “Disponibilidade

(Uptime) – AGREGADO”.

7. Anexos

- **7.1.** Anexo I - Relatório Bruto Disparos - Fornecedor/Broker Wetalkie - Mar/26
- **7.2.** Anexo II - Relatório Bruto Mensagens - Fornecedor/Broker Wetalkie - Mar/26
- **7.3.** Anexo III - Extrações DL - Latência e Sessões Receptivas - Mar/26
- **7.4.** Anexo IV - Script e2e_p98.py

Ingrid Herdeiro Gomes
Diretora de Diretoria de Experiência Digital
Matrícula: 623.495-1